

고급인공지능 팀 프로젝트 및 작업 공간

김태영: 추천 AI 모델 학습 방식 - RAG

▼ GPT 방식

네, 지금 말씀하신 방향이라면 기존의 단순한 "뉴스 키워드 시각화"보다 한 단계 더 발전한 형태로 정리할 수 있습니다.

다만 한 가지는 표현을 조금 다듬는 게 좋습니다.

RAG는 보통 "모델을 새로 학습시키는 것"보다는, 외부 문서를 검색해서 LLM이 참고하도록 만드는 방식입니다.

그래서 기획안에서는

- "AI 모델을 학습시킨다"
- 보다는
- "뉴스 및 시황 데이터를 검색·요약·근거 제시하는 RAG 기반 분석 시스템을 구축한다"

이렇게 쓰는 쪽이 더 정확하고, 교수님이 봐도 더 전문적으로 보입니다.

아래에 바로 댓글로 제출 가능한 형태로, 지금 주제에 맞춰 **완전히 커스텀 버전**으로 자세히 정리해드리겠습니다.

[Team Building]

팀 이름 : MacroPulse AI (매크로펄스 AI)

(의도: 금리, 환율, 원자재, 금, 구리, 국채 수익률 등 거시경제 지표의 움직임을 실시간 흐름(Pulse)으로 읽어내고, 뉴스와 발언이 시장에 어떤 영향을 미치는지를 AI로 해석하겠다는 의미를 담음)

팀장 : [본인 이름]

팀원 : [팀원 이름]

팀 문화 : "Signal over Noise"

단순한 뉴스 나열이 아니라, 실제 시장에 영향을 주는 핵심 신호(Signal)를 찾아내는 것을 최우선 가치로 삼습니다.

매일 쏟아지는 경제 뉴스 속에서 불필요한 정보(Noise)를 줄이고, 금리·환율·원자재·정책 발언처럼 지수 변동에 직접적인 영향을 줄 수 있는 정보만 선별하여 분석합니다.

또한 2인 팀의 특성상 빠른 의사결정과 높은 실행력을 강점으로 삼아, 역할을 명확히 나누되 결과는 함께 검증하는 협업 문화를 지향합니다.

프로젝트 관리 방법론 : Agile-Kanban

본 프로젝트는 뉴스 크롤링, 데이터 정제, 키워드 가중치 설계, RAG 기반 질의응답, 지수 차트 시각화 등 여러 작업이 병렬적으로 진행되어야 하므로 유연한 관리 방식이 적합합니다.

따라서 '데이터 수집 - 전처리 - 분석 로직 - 시각화 - 검증 - 발표 자료'의 흐름으로 작업을 구분하고, 칸반 보드를 활용해 진행 상태를 관리합니다.

각 기능을 작은 단위로 먼저 구현한 뒤, 실제 뉴스 데이터를 넣어 빠르게 테스트하면서 오류와 병목을 조기에 발견하는 방식으로 프로젝트를 진행합니다.

역할 분담 :

- 팀장 : 전체 서비스 기획, 데이터 흐름 설계, 지수 산출 로직 설계, 발표 총괄
- 팀원 : 뉴스 크롤링, 데이터 정제, RAG 검색 파이프라인 구현, 시각화 보조 및 테스트
- 공통 업무 : 결과 검증, 키워드 사전 보완, 발표 자료 제작

[Planning]

서비스 이름 : MarketEcho Index (마켓에코 인덱스)

(의도: 정치인, 중앙은행, 국가, 기업, 원자재 시장 관련 발언과 사건이 실제 시장에 메아리(Echo)처럼 반응하여 가격과 심리에 영향을 주는 현상을 하나의 지수(Index)로 시각화한다는 의미를 담음)

서비스 목적 :

"최신 경제 뉴스와 주요 발언을 기반으로, 국채 수익률·금·구리·환율 등 거시 변수의 급등·급락 원인을 직관적으로 이해할 수 있도록 돕는 RAG 기반 AI 분석 및 지수 시각화 서비스"

타겟 유저 or 유즈케이스 :

거시경제 흐름에 관심은 있지만, 뉴스와 가격 움직임 사이의 연결을

이해하기 어려운 대학생, 초보 투자자, 일반 소비자

예 :

사용자가 '왜 최근 원달러 환율이 다시 상승했는가?', '왜 금값이 재 상승했는가?', '왜 구리 가격이 반등했는가?'와 같은 질문을 입력하면,

시스템이 Yahoo Finance 등에서 수집한 최신 뉴스 기사와 발언 데이터를 검색하여 관련 내용을 요약하고,

핵심 키워드(예: 국채 수익률, 관세, 지정학 리스크, 달러 강세, 중앙은행 발언, 인플레이션 우려)를 근거와 함께 제시합니다.

동시에 시간대별 뉴스 영향 점수를 반영한 자체 지수 차트를 제공하여, 특정 시점에 어떤 뉴스 또는 발언이 시장에 영향을 주었는지 시각적으로 보여줍니다.

서비스 기획 추가 설명 :

본 서비스는 Python과 Google Colab 환경을 기반으로 구현되는 거시경제 뉴스 해석 시스템입니다.

우선 Yahoo Finance에 게시되는 최신 뉴스 기사와 관련 시황 데이터를 수집한 뒤, 기사 제목·본문·작성 시각·관련 키워드를 정제하여 분석 가능한 형태로 저장합니다.

이후 자연어 처리 기법을 활용해 핵심 키워드와 개체명(인물, 국가, 기관, 원자재, 통화, 금리 관련 용어)을 추출하고, 각 뉴스가 시장에 줄 수 있는 영향도를 점수화합니다.

특히 본 프로젝트는 단순 빈도 분석에서 그치지 않고,

- 1) 기사 제목 포함 여부,
 - 2) 특정 인물 또는 국가 언급 빈도,
 - 3) 금리·환율·원자재 관련 핵심 단어 등장 비중,
 - 4) 뉴스의 최신성,
 - 5) 같은 주제를 다루는 기사들의 반복성
- 등을 반영하여 뉴스 영향 점수를 계산합니다.

이렇게 계산된 점수는 시간 흐름에 따라 누적되며, 최종적으로 'Macro Reaction Index' 형태의 자체 지수 차트로 시각화됩니다.

해당 차트는 나스닥100 선물 지수처럼 시간에 따라 상승과 하락이 이어지는 형태를 가지지만,

실제 가격 데이터를 예측하는 것이 아니라 뉴스와 발언이 시장 심리에 미치는 상대적 충격 강도를 표현하는 데 목적이 있습니다.

또한 본 프로젝트에는 RAG(Retrieval-Augmented Generation) 구조를 적용합니다.

사용자가 특정 현상에 대해 질문하면,
저장된 최신 뉴스 기사 중 관련성이 높은 문서를 우선 검색한 뒤, 대형언어모델이 검색된 기사 내용을 바탕으로 원인을 설명합니다.
이를 통해 AI가 근거 없는 추정을 하는 것이 아니라, 실제 뉴스 기사와 핵심 문장을 바탕으로 설명을 생성하도록 설계합니다.

최종적으로 사용자는 다음과 같은 기능을 경험할 수 있습니다.

- 최신 경제 뉴스 자동 수집
- 주요 키워드 및 개체명 추출
- 뉴스 영향 점수 계산
- 거시경제 이벤트 반응 지수 차트 제공
- 특정 현상에 대한 RAG 기반 원인 설명
- 특정 시점 급등·급락 구간에 영향을 준 뉴스 키워드 확인

본 서비스는 경제 뉴스 해석을 어려워하는 일반 사용자에게,
단순 기사 나열이 아닌 '왜 이런 현상이 발생했는지'를 구조적으로 이해할 수 있도록 돕는 설명형 AI 도구를 목표로 합니다.

위 버전은 제출용으로 꽤 깔끔한 편인데, 지금 주제에 맞게 더 설득력 있게 보이게 하려면 아래 포인트를 같이 이해하고 계시면 좋습니다.

1. 이 프로젝트의 핵심 정체성

이 프로젝트는 엄밀히 말하면 **가격 예측 AI**가 아니라,

뉴스 기반 시장 반응 해석 AI에 가깝습니다.

이 차이가 중요합니다.

왜냐하면 “금값이 왜 오르는지”, “환율이 왜 뛰는지”를 설명하는 건 비교적 현실적이고 발표도 자연스러운데,

“정확히 얼마나 오를지 예측한다”로 가면 난이도가 갑자기 매우 올라가기 때문입니다.

그래서 프로젝트 소개 문구는 이런 식으로 잡는 게 좋습니다.

- 뉴스와 발언이 시장 심리에 미치는 영향을 정량화하는 서비스
- 거시경제 현상의 원인을 설명하는 AI 분석 도구
- 경제 뉴스와 지표 움직임을 연결해주는 시각화 시스템

2. “나스닥 100 선물 지수 차트처럼”이라는 표현은 이렇게 바꾸는 게 좋습니다

그 표현 자체는 직관적이지만, 제출 문안에서는 조금 더 학술적으로 바꾸는 편이 좋습니다.

추천 표현:

- 시계열 기반 이벤트 반응 지수 차트
- 뉴스 충격 강도 시각화 차트
- 거시 이슈 반응 인덱스
- 시장 심리 반응 곡선

즉, 실제 선물 가격을 모사한다기보다

뉴스에 대한 시장 반응 강도를 선형 시계열 지수로 표현한다고 쓰는 게 더 정확합니다.

3. 이 프로젝트에서 “급등·급락의 원인”으로 넣기 좋은 요소

사용자 아이디어를 살리려면, 점수화 대상이 분명해야 합니다.

예를 들어 이런 식으로 잡으시면 됩니다.

인물

- 미국 대통령
- 연준 의장
- 재무장관
- 중국 정부 고위 인사
- 주요 기업 CEO

국가/기관

- 미국
- 중국
- 한국
- 연준(Fed)
- ECB

- BOJ

이벤트

- 금리 인상/동결/인하
- 관세 정책
- 전쟁 및 지정학 갈등
- 원자재 공급 차질
- 경기침체 우려
- 인플레이션 재가속
- 실업률/소비자물가 발표

이런 항목들이 뉴스 안에 등장할 때 점수를 부여해서,
그 점수가 시간대별로 누적되면 자체 차트를 만들 수 있습니다.

4. 기술적으로는 이렇게 쓰면 더 자연스럽습니다

발표나 보고서용으로는 아래 표현이 괜찮습니다.

사용 기술

- Python
- Google Colab
- requests / BeautifulSoup
- pandas / numpy
- matplotlib / plotly
- scikit-learn
- sentence-transformers 또는 임베딩 모델
- FAISS 또는 ChromaDB
- LangChain 계열 도구(선택)

시스템 흐름

1. Yahoo Finance 최신 뉴스 수집
2. 기사 제목·본문 정제

3. 키워드 및 개체명 추출
4. 뉴스 영향 점수 계산
5. 시계열 지수 생성
6. RAG용 문서 저장소 구축
7. 사용자 질문 입력
8. 관련 기사 검색
9. AI가 근거 기반 답변 생성
10. 차트와 함께 결과 제공

이 구조가 잡히면 교수님이 봐도 “단순 크롤링 과제”가 아니라

데이터 수집 + NLP + RAG + 시각화가 합쳐진 프로젝트로 보입니다.

5. 다만 2인 팀 기준으로는 범위를 조금 조절하셔야 합니다

이건 현실적으로 중요합니다.

지금 아이디어를 그대로 다 넣으면 범위가 커질 수 있어서,

처음에는 아래 정도로 줄이는 게 좋습니다.

1차 구현 범위

- Yahoo Finance 뉴스 1개 소스만 사용
- 기사 50~100개 정도 수집
- 제목 중심 키워드 추출
- 키워드 점수 기반 지수 차트 생성
- RAG 질문답변 3~5개 정도 데모

2차 확장 가능 기능

- 본문까지 반영
- 감성 점수 추가
- 인물/국가별 영향도 비교
- 금/환율/구리/국채별 세부 지수 분리
- Streamlit 대시보드

처음부터 너무 크게 잡지 말고,

- **“설명 가능한 최소 기능”**을 먼저 완성하는 게 훨씬 좋습니다.

6. 제출용으로 더 있어 보이게 만드는 한 줄 요약

아래 한 줄은 따로 기억해두시면 좋습니다.

“본 프로젝트는 최신 경제 뉴스와 주요 발언 데이터를 수집하여, 거시경제 현상의 원인을 RAG 기반으로 설명하고, 뉴스 충격 강도를 시계열 지수 형태로 시각화하는 Python 기반 AI 분석 시스템이다.”

이 문장 하나로 프로젝트 정체성이 거의 정리됩니다.

7. 댓글용으로 조금 더 짧은 버전이 필요하다면

아주 길게 쓰기 부담되면 아래처럼 압축도 가능합니다.

서비스 이름 : MacroPulse AI

서비스 목적 :

최신 경제 뉴스와 주요 발언을 분석하여 국채 수익률, 금값, 구리 가격, 원달러 환율 등의 변동 원인을 쉽게 이해할 수 있도록 돕는 RAG 기반 AI 분석 서비스

타겟 유저 :

거시경제 흐름을 이해하고 싶은 대학생, 초보 투자자, 일반 소비자

서비스 기획 추가 설명 :

Yahoo Finance의 최신 뉴스 기사를 Python으로 수집하고, 기사 내 핵심 키워드와 인물·국가·기관 정보를 추출하여 뉴스 영향 점수를 계산합니다.

이 점수를 시간 흐름에 따라 누적하여 나스닥100 선물 차트와 유사한 형태의 자체 이벤트 반응 지수를 생성합니다.

또한 RAG 구조를 활용해 사용자가 “왜 금값이 올랐는가?”, “왜 환율이 상승했는가?” 같은 질문을 입력하면, 관련 뉴스 기사를 근거로 원인을 요약하여 설명하는 AI 시스템을 구현합니다.

원하시면 다음 답변에서 바로 이어서

이 기획안에 맞는 2인 팀 역할 분담표랑 Google Colab 기준 개발 순서까지 붙여서 실전형으로 정리해드리겠습니다.

▼ Gemini 방식

태영 님이 관측하신 시장의 흐름(국채 금리, 금, 구리, 환율의 동반 상승)은 매우 거대하고 복잡한 '**매크로(거시 경제)의 변곡점**'을 시사합니다.

기존의 단순 뉴스 크롤링을 넘어, 이러한 복잡다단한 변수들과 특정 인물의 발언 사이의 인과관계를 **RAG(검색 증강 생성) 기반 AI 모델**로 풀어내고, 이를 소비자 눈높이에 맞춘 '**가상의 나스닥 차트**'처럼 시각화하겠다는 기획은 매우 혁신적이며 전문적인 접근입니다.

이전 프로젝트가 데이터의 '나열'이었다면, 이번 기획은 데이터의 '**해석과 흐름의 시뮬레이션**'입니다. 요청하신 내용에 맞춰, 두 분이 진행하기 가장 효율적인 형태로 팀 빌딩과 기획안을 다시 설계해 드립니다.

[Team Building] (Macro/RAG 맞춤형)

팀 이름 : MacroPulse (매크로펄스)

(의도: 자본 시장의 거대한 맥박(Pulse)과도 같은 국채 금리, 원자재, 환율의 복합적인 움직임을 포착하겠다는 의지입니다. 단순 데이터가 아니라, 시장의 거시적인 흐름을 데이터로 증명하겠다는 전문성을 브랜딩합니다.)

팀장 : 태영 (Backend & RAG Architect)

- 야후 파이낸셜 뉴스 및 원자재 데이터 수집 파이프라인 구축
- Google Colab 기반 RAG 엔진 설계 및 임베딩 모델 구현
- 가상 지수(Synthetic Index) 산출 수식 설계 및 시각화 엔드포인트 개발

팀원 B : (NLP & Economic Analyst) (가칭)

- 수집된 뉴스/발언 데이터의 감성 분석 및 매/비둘기파 점수화
- 전공 서적(ADP 가이드 등) 기반 시계열 분석 및 가중치 모델링
- RAG 프롬프트 엔지니어링 및 소비자 친화적 해설 텍스트 생성

팀 문화 : "Data-Driven Causality (데이터 기반 인과관계)"

모든 시장 변동은 원인이 있다는 믿음 하에, 흩어져 있는 뉴스 데이터에서 핵심적인 인과(특정 인물의 발언, 국가 정책)를 데이터로 증명합니다. 주 2회, 수집된 RAG 데이터와

실제 지수 변동 간의 괴리를 분석하는 '로직 검증 회의'를 통해 모델의 신뢰도를 높입니다.

프로젝트 관리 방법론 : Agile-Kanban

뉴스 수집기, 감성 모델, RAG 엔진, 지수화 등 각 구성 요소의 개발 상태를 가시화합니다. RAG 모델 학습 및 검증 주기가 잦은 프로젝트 특성상, 병목 구간을 즉시 확인하고 유연하게 대처합니다.

[Planning] (RAG & Synthetic Index 맞춤형)

서비스 이름 : MarketEcho (마켓에코)

(의도: "시장은 발언에 메아리(Echo)친다." 특정 인물의 발언이나 국가의 활동이 자본 시장(국채, 원자재, 환율)에 어떤 거대한 파동을 일으키는지, RAG 기반 AI가 그 메아리를 해석하여 지수 차트로 보여주는 서비스임을 강조합니다.)

서비스 목적 : "복잡한 글로벌 매크로 유동성 파동을 직관적인 가상 지수 차트로 보여주는 RAG 기반 경제 교육 플랫폼"

타겟 유저 or 유즈케이스 : "갑작스러운 환율 상승이나 원자재 가격 변동의 원인을 알고 싶어 하는 이성적인 개인 투자자 및 금융 소비자"

- **예시:** "오늘 왜 갑자기 국채 금리가 오르고 구리 가격이 동반 상승했지?"라는 질문에, AI가 야후 파이낸셜에서 수집한 Fed 의장의 어제 발언과 중국의 경기 부양책 뉴스를 RAG로 검색해와서, 가상의 'MarketEcho 지수'가 급등하는 차트와 함께 "연준의 긴축 우려가 여전한 가운데, 중국의 유동성 공급 기대감이 원자재 가격을 끌어올렸다"는 소비자 친화적 해설을 제공하는 케이스.

서비스 기획 추가 설명 (핵심 기술 파이프라인) :

1. **데이터 수집 (Data Factory):** `BeautifulSoup` / `yfinance` 등을 활용하여 야후 파이낸셜의 매크로 뉴스, 특정 인물(Fed 의장 등)의 발언 전문, 그리고 국채 금리, 금, 구리, 환율, 알루미늄(별도 소스 확보 필요)의 실제 시세 데이터를 실시간 크롤링합니다.
2. **Google Colab 기반 RAG 학습 및 추론 (Core Brain):**
 - **Retrieval:** 수집된 텍스트 데이터를 벡터 DB에 임베딩하여 저장합니다. 소비자가 질문하면 관련 뉴스를 실시간 검색해옵니다.
 - **Generation:** 전문 서적(ADP 가이드 등)의 지식을 기반으로 설계된 프롬프트를 통해, AI가 검색된 뉴스의 핵심 내용과 시장 영향력(매파적(+), 비둘기파적(-))을 분석합니다. 이 과정에서 '할루시네이션'을 최소화합니다.
3. **가상 지수(Synthetic Index) 산출 및 시각화 (Dashboard):**

- **지수 산식:** 각 asset class(국채, 원자재, 환율)의 뉴스 기반 감성 점수에 태영 님이 강조하신 '유동성 가중치'를 곱하여 하나의 복합 'MacroPulse 지수'를 산출합니다.

$$MarketEcho_Index_t = \sum_{i=1}^n (w_i \times Sentiment_Score_i)$$

(여기서 \$w_i\$는 유동성 환경에 따른 asset별 가중치)

- **시각화:** 산출된 지수를 시간 축에 따라 누적하여 '**나스닥 100 선물 차트'처럼 캔들 차트로 구현합니다. 특정 인물의 발언이 있던 시점에 AI 해설을 마커로 표시하여 급등락의 인과관계를 명확히 보여줍니다.



태영 님을 위한 추가 조언

이 기획안은 태영 님의 매크로에 대한 깊은 통찰력과 최신 AI 기술(RAG)을 완벽하게 결합한 형태입니다.

- **할루시네이션 해결:** 태영 님 말씀처럼 RAG를 사용하면 AI가 외부 데이터(야후 뉴스)를 기반으로 답변하기 때문에, 단순히 AI 모델 내부에 의존하는 것보다 훨씬 신뢰성 높은 결과물을 얻을 수 있습니다.
- **포트폴리오 가치:** 단순한 기능 구현이 아니라, '**금융 도메인 지식'을 데이터 전처리와 지수화 수식에 녹여냈다는 점이 이 프로젝트를 실무 수준으로 끌어올릴 것입니다.

두 분에서 이 기획안을 바탕으로 Google Colab에서 가장 먼저 구현해 볼 '**야후 뉴스 크롤링 및 RAG 임베딩 기초 코드'부터 작성을 시작해 보시는 것은 어떨까요?

▼ 최종 양식

[Team Building]

팀 이름: 뉴스닥

의도: 뉴스의 "News"와 나스닥의 "sdaq"

팀장: 김한빈

팀원: 김태영

팀 문화: TFITH - The first is the Hardest

첫 발걸음(시작)이 항상 가장 어렵다는 의미로, 무슨 일이든 처음 시작할 때가 가장 힘들고 막막하지만, 일단 시작하면 그 다음부터는 정석대로 과정을 해쳐 나갈 수 있기 때문에 한국 속담의 "시작이 반이다"와 같은 마인드

프로젝트 관리 방법론: Agile - Kanban

뉴스 크롤링, 데이터 정제, 키워드 가중치 설계, RAG 기반 질의응답, 지수 차트 시각화 등 여러 작업이 병렬적으로 진행되어야 하기 때문에 유연한 관리 방식이 적합하다고 생각합니다.

따라서 '데이터 수집 - 전처리 - 분석 로직 - 시각화 - 검증 - 발표자료'의 흐름으로 작업을 구분하고, 칸반 보드를 활용해 진행 상태를 관리합니다.

• --

[Planning]

서비스 이름: MarketEcho Index (마켓에코 인덱스)

의도: 정치인, 중앙은행, 국가, 기업, 원자재 시장 관련 발언과 사건이 실제 시장에 메아리(Echo)처럼 반응하여 가격과 심리에 영향을 주는 현상을 하나의 지수(Index)로 시각화한다는 의미를 담고 있습니다.

서비스 목적: 최신 경제 뉴스와 주요 발언을 기반으로, 국채 수익률 · 금 · 은 · 구리 · 알루미늄 · 기름 · 환율 등 거시 변수의 급등 · 급락 원인을 직관적으로 이해할 수 있도록 돕는 RAG 기반 AI 분석 및 지수 시각화 서비스

타겟 유저 & 유즈케이스: 거시경제 흐름에 관심이 있어도 뉴스와 가격 움직임 사이의 연결을 이해하기 어렵거나 시간이 없어서 간단 요약を 원하는 대학생, 초보 투자자, 일반 소비자 등 넓은 의미에서는 모든 계층을 타겟으로 하고, 좁은 의미로는 월 \$5와 연으로 \$48를 지불할 수 있는 가처분 소득을 가진 계층

예시: 사용자가 '왜 최근 원달러 환율이 다시 상승했는가?', '왜 금값이 재상승했는가?', '왜 국채 수익률이 급등하는가?'와 같은 질문을 입력하면, 시스템이 Yahoo Finance 등에서 수집한 최신 뉴스 기사와 발언 데이터를 검색, 관련 내용들을 요약하고 핵심 키워드로 예를 들면 국채 수익률, 관세, 지정학 리스크, 달러 강세, 중앙은행 발언, 인플레이션 우려를 실제 존재하는 근거와 함께 제시합니다. 동시에 시간대별 뉴스 영향 점수를 반영한 자체 지수 차트를 제공하여 특정 시점에 어떤 뉴스 또는 발언이 시장에 영향을 주었는지 시각적으로 보여줍니다.

서비스 기획 추가 설명: 본 서비스는 Python과 Google Colab 환경을 기반으로 구현되는 거시경제 뉴스 해석 시스템으로, 우선 Yahoo Finance에 게시되는 최신 뉴스 기사와 관련 시황 데이터를 수집한 뒤, 기사 제목 · 본문 · 작성 시각 · 관련 키워드를 정제하여 분석 가능한 형태로 저장합니다. 이후 자연어 처리 기법을 활용해 핵심 키워드와 개체명(인물, 국가, 기관, 원자재, 통화, 금리 관련 용어)를 추출하고 각 뉴스가 시장에 줄 수 있는 영향도를 점수화합니다.

본 시스템은 RAG(Retrieval-Augmented Generation) 구조를 활용하여 사용자 질문에 대한 설명을 생성합니다. 사용자가 특정 거시경제 현상에 대해 질문하면, 저장된 뉴스 데이터 중 관련성이 높은 문서를 검색하고 검색된 문서에서 핵심 문장과 키워드를 추출

한 뒤 이를 기반으로 대형 언어 모델이 근거 중심의 답변을 생성합니다. 이 과정은 단순 생성형 AI가 아닌, 실제 데이터에 기반한 설명을 제공하는 것을 목표로 합니다.

▼ 실제 분석 기법 관련 내용

김태영 님, '**데이터 분석 전문가 가이드(ADP)**'의 방법론을 바탕으로, "영향도를 점수화합니다." 이후의 프로젝트 상세 설계 내용을 전문적이고 구체적으로 이어 작성해 드립니다.

이 내용은 실제 ADP 교재의 **제4과목(데이터 분석 - 비정형 데이터 마이닝/통계분석)**과 **제5과목(데이터 시각화)**의 핵심 프로세스를 파이썬 구현 관점에서 녹여낸 것입니다.

[Service Logic Detail: After Scoring]

1. 비정형 데이터 마이닝을 통한 텍스트 분석 고도화 (ADP 4과목 4장)

추출된 뉴스 데이터는 단순 빈도 분석을 넘어, 파이썬의 **Natural Language Toolkit(NLTK)** 과 **KoNLPy** 를 활용한 **텍스트 마이닝** 과정을 거칩니다.

- **감성 분석(Sentiment Analysis):** 기사 내 형용사와 동사를 분석하여 해당 뉴스가 시장에 '긍정(Bullish)' 혹은 '부정(Bearish)' 신호를 주는지 판별합니다.
- **TF-IDF 및 Word2Vec:** 뉴스 간의 유사도를 측정하여 중복된 노이즈를 제거하고, '국채 수익률-달러 강세-금값 하락'과 같이 의미론적으로 연결된 키워드 군집 (Clustering)을 형성합니다. 이를 통해 지수 변동의 핵심 동인(Driver)을 식별합니다.

2. 통계적 유효성 검증 및 지수 최적화 (ADP 4과목 2장)

산출된 'Macro Reaction Index'가 실제 시장 지표와 얼마나 일치하는지 통계적으로 검증합니다.

- **상관관계 분석(Correlation Analysis):** 자체 산출 지수와 실제 나스닥100 선물, 원/달러 환율 등의 가격 데이터 간 상관계수 ρ 를 계산하여 로직의 신뢰도를 점검합니다.
- **회귀 분석(Regression Analysis):** 특정 발언이나 키워드가 지수 변동에 미치는 영향력을 계수화하여, 뉴스 점수 산출 공식의 가중치를 동적으로 조정(Parameter Tuning)합니다.

3. RAG(Retrieval-Augmented Generation) 기반 검색 파이프라인 (ADP 4과목 3장 응용)

사용자의 질문에 대해 단순한 생성형 답변이 아닌, **근거 기반의 답변**을 제공하기 위해 다음과 같은 아키텍처를 설계합니다.

- **Vector DB 구축:** 전처리된 뉴스 본문을 임베딩(Embedding)하여 **ChromaDB** 또는 **FAISS** 와 같은 벡터 데이터베이스에 저장합니다.
- **컨텍스트 추출:** 사용자가 "왜 금값이 올랐어?"라고 질문하면, 관련성이 높은 상위 K 개의 뉴스 문장을 검색하여 LLM(대형언어모델)에 전달합니다. 이를 통해 모델의 환각(Hallucination) 현상을 방지하고 정확한 뉴스 출처를 제시합니다.

4. 시각화 인사이트 프로세스 (ADP 5과목)

단순한 선 그래프를 넘어, 데이터의 '맥락'을 전달하는 시각화 설계를 적용합니다.

- **시각화 디자인:** **Plotly** 라이브러리를 사용하여 시간 흐름에 따른 지수 차트를 구현하고, 급등락이 발생한 특정 시점에 마우스를 올리면 해당 구간의 핵심 뉴스 키워드가 툴팁(Tooltip)으로 표시되게 합니다.
- **인사이트 전달:** 지수 차트와 함께 '핵심 영향 요인 트리맵(Treemap)'을 배치하여, 현재 시장 심리를 지배하고 있는 국가나 기관(예: 미 연준, FOMC, 지정학적 리스크 등)의 비중을 직관적으로 보여줍니다.

[Expected Output]

이러한 전문적인 데이터 분석 프로세스를 거친 최종 결과물은 다음과 같은 가치를 제공합니다.

- **정교한 데이터 정제:** ADP 가이드의 '데이터 매트' 구성 원리에 따라 분석에 최적화된 데이터 구조를 확보합니다.
- **논리적 근거 제시:** 통계적 분석과 비정형 마이닝이 결합되어, AI의 답변이 단순한 추측이 아닌 데이터에 기반한 '해설'이 됩니다.
- **사용자 중심의 시각화:** 데이터 시각화 인사이트 프로세스를 준수하여 초보 투자자도 거시경제의 흐름을 즉각적으로 이해할 수 있는 대시보드를 제공합니다.

위 내용이 태영 님의 팀 빌딩 및 플랜 설계서의 완성도를 높이는 데 도움이 되기를 바랍니다. 혹시 이 중 **파이썬으로 구현할 구체적인 통계 수식이나 텍스트 전처리 코드 예시**가 필요하신가요?

▼ 4: 데이터 분석 - 2장 통계 분석

야후 파이낸스(Yahoo Finance)에서 수집한 **뉴스 기사(텍스트 데이터)**를 **USArrests** 와 같은 **수치 데이터**처럼 분석하기 위해서는, 먼저 텍스트를 숫자로 변환하는 '**피처 엔지니어링(Feature Engineering)**' 과정이 반드시 필요하다.

크롤링한 뉴스 데이터를 통계 분석 모델에 적용하는 체계적인 절차

통계 분석 기법들은 **RAG(Retrieval-Augmented Generation, 검색 증강 생성)** 기반의 AI 모델을 고도화하는 데 매우 강력한 기반 데이터로 활용될 수 있다.

R의 `plot(fit)` 함수가 그려주는 그림은 통계학에서 **스크리 산점도(Scree Plot)**라고 불린다. 각 주성분이 전체 데이터의 분산을 얼마나 설명하는지(중요도)를 시각화하여, 몇 개의 주성분까지 사용할지 결정하는 기준이 된다.

야후 파이낸스에서 크롤링한 **텍스트(뉴스)**를 이 단계까지 가져가기 위해서는 **비정형 데이터를 수치형 행렬로 변환**하는 전처리 과정이 핵심이다.

1. 텍스트 전처리 및 수치화 파이프라인

뉴스 기사는 숫자 데이터가 아니기 때문에 통계 모델이 인식할 수 있는 **문서-단어 행렬(Document-Term Matrix, DTM)** 형태로 변환해야 한다.

텍스트 정제 (Cleaning)

- **특수문자 및 불용어 제거:** 뉴스 기사에 포함된 HTML 태그, 구두점, 'the', 'a'와 같은 의미 없는 단어(Stopwords)를 제거한다.
- **어근 추출 (Stemming/Lemmatization):** 'trading', 'traded', 'trades'를 모두 'trade'라는 하나의 단어로 통일하여 변수의 개수를 효율적으로 관리한다.

▼ 인과관계 vs 상관관계

• 상관관계 (Correlation)

- 두 변수 간 **함께 변하는 관계**
- 원인/결과는 모름

예:

- 아이스크림 판매량이 늘어남 → 익사 사고도 늘어남 → 단순히 "여름"이라는 공통 요인으로 인한 것

- **인과관계 (Causality)**

- 한 변수가 다른 변수에 **직접적인 영향을 줌**

예:

- 가격 인상으로 인해 수요 감소

인과관계 성립 조건 → 3가지

1. **시간적 선행성**

- 원인이 결과보다 먼저 발생해야 한다.

2. **공변성**

- 두 변수 간 관계가 존재해야 한다, 즉 같이 변해야 한다는 뜻이다

3. **비허위성 (가장 중요함)**

- 제 3의 변수(혼란변수)가 없어야 한다

이게 핵심으로 대부분 "가짜 인과관계"는 여기서 발생하기 때문이다.

혼란변수 (Confounding Variable)

인과분석에서 가장 중요한 개념이다.

예:

- 커피 소비량 증가 ↔ 심장병 증가 → 실제 원인은 흡연

즉,

- $X \rightarrow Y$ 처럼 보이지만
 - 실제로는 Z가 둘 다 영향을 끼친다
-

▼ **마켓에코 인덱스** 같은 대규모 텍스트 데이터와 정형 수치 데이터를 결합해 분석하는 프로젝트의 최우선 고려사항

단순한 데이터 저장을 넘어 '**분석의 효율성**'과 '**데이터의 신뢰성**'을 최우선으로 고려해야 한다.

현업 데이터 엔지니어들의 시계열 분석 및 RAG 시스템을 위한 DB 설계 시 가장 깊게 고민하는 5가지 핵심 요소들

1. 시계열 데이터(Time-Series)의 정밀도와 동기화

'메아리(Echo)' 현상을 분석하려면 뉴스가 발생한 시점과 주가가 움직인 시점을 정확히 매칭해야 한다.

- **타임스탬프 표준화:** 서버 시간, 뉴스 발행 시간, 시장 거래 시간이 제각각일 수 있다. 이를 모두 **UTC(협정 세계시)**로 통일하여 저장하고, 조회 시에만 현지 시간으로 변환하는 설계가 필수적이다.
- **데이터 간격(Granularity) 관리:** 주가 데이터는 1분봉, 15분봉, 일봉 등 다양한 주기를 가진다. DB 설계 시 각 주기별로 테이블을 분리하거나, 원천 데이터를 바탕으로 실시간 집계(Aggregation)를 수행할 수 있는 구조를 고민해야 한다.

2. 하이브리드 데이터 모델링 (RDBMS + Vector DB)

비정형 데이터(뉴스)와 정형 데이터(주가, 지수)는 저장 방식과 검색 메커니즘이 완전히 다르다.

- **관계형 DB (PostgreSQL/MySQL):** 주가, 종목 정보, 뉴스 메타데이터(발행인, URL), 감성 점수 등 정형 데이터를 저장한다. 조인(Join) 연산을 통해 데이터 간의 관계를 명확히 규정한다.
- **벡터 DB (ChromaDB/Pinecone):** 뉴스 본문의 임베딩(Embedding) 벡터를 저장한다. RAG 시스템에서 유사한 의미의 문장을 빠르게 찾기 위해 사용된다.

- **연결 고리(Mapping):** 두 DB 사이를 이어주는 'Unique ID(예: News_ID)' 관리가 매우 중요하다. 벡터 검색 결과로 나온 ID를 가지고 SQL DB에서 상세 정보를 즉시 끌어올 수 있어야 한다.

3. 메타데이터 설계와 출처 추적 (Data Provenance)

RAG 기반 AI가 답변을 생성할 때, "어떤 근거로 이런 말을 하는가?"를 증명하는 것이 서비스의 신뢰도를 결정한다.

- **출처 관리:** 뉴스 테이블에 `source_url`, `publisher`, `author` 뿐만 아니라, 해당 뉴스를 크롤링한 시각(`collected_at`)까지 세밀하게 기록한다.
- **중복 제거 로직:** 여러 매체에서 동일한 뉴스를 송고할 경우, 제목이나 본문의 유사도를 체크하여 중복 데이터를 필터링하는 로직이 DB 수준 혹은 전처리 단계에서 반영되어야 한다.

4. 성능 최적화를 위한 파티셔닝(Partitioning) 및 인덱싱

데이터가 수만 건 이상 쌓이기 시작하면 검색 속도가 급격히 느려진다. 특히 뉴스 데이터는 매일 방대하게 쌓이는 특성이 있다.

- **테이블 파티셔닝:** 날짜별(예: 월 단위 또는 주 단위)로 테이블을 물리적으로 분할한다. 최신 뉴스 위주로 조회하는 RAG 시스템의 특성상, 전체 테이블을 뒤지지 않고 특정 기간의 파티션만 조회하게 하여 성능을 극대화한다.
- **복합 인덱스(Composite Index) 활용:** 단순히 `ticker` 나 `date` 하나에만 인덱스를 거는 것이 아니라, `(ticker, date)` 와 같이 자주 함께 쓰이는 컬럼을 묶어 인덱스를 설계함으로써 쿼리 성능을 높인다.

5. 분석을 위한 파생 데이터(Derived Data) 관리

매번 계산하기 복잡한 수치들은 미리 계산하여 저장해 두는 것이 효율적이다.

- **감성 점수 및 상관계수:** 뉴스 본문을 분석하여 얻은 감성 점수 (S) 나 특정 자산과의 상관계수(ρ)는 실시간으로 계산하기에는 연산 비용이 큼니다. 따라서 별도의 테이블에 미리 계산된 값을 저장해 두고(Materialized View 또는 캐싱), 필요할 때 즉시 불러오는 구조를 택합니다.

Echo Index_t = ∑_{i=1}ⁿ (W_i × Sentiment_{i,t})

(위 수식과 같이 가중치(W)가 적용된 지수 산출 로직을 DB에서 효율적으로 처리하기 위한 설계가 필요합니다.)

▼ 개발 과정 및 단계

태영님께서 기획하신 **MarketEcho(마켓에코)** 프로젝트의 전체 파이프라인을 고려하여, 00 부터 04 까지의 파일 명칭과 각 파일의 핵심 역할을 정리해 드립니다. 이 구조는 구글 드라이브와 깃허브 연동 시 경로 꼬임을 방지하고, **Gemini API**와의 시너지를 극대화할 수 있도록 설계되었습니다.

📁 MarketEcho 프로젝트 파일 로드맵

파일명	주요 기능 및 역할	비고
00_Env.ipynb	환경 설정 및 보안: 라이브러리 설치, 구글 드라이브 마운트, GH_TOKEN 및 GOOGLE_API_KEY 인증 관리.	인프라 구축
01_Data_Factory.ipynb	데이터 수집 엔진: Yahoo Finance RSS 뉴스 및 yfinance 마켓 지수 수집, context_text 생성을 통한 RAG 기초 데이터 확보.	수집 완료
02_RAG_Architect.ipynb	벡터 DB 구축: Gemini API(text-embedding-004)를 활용한 뉴스 데이터 임베딩 및 검색(Retrieval) 로직 구현.	다음 단계
03_Sentiment_Analyzer.ipynb	인공지능 분석: Gemini API의 추론 능력을 활용한 뉴스의 매/비둘기파 성향 점수화 및 시장 영향력 해석.	분석 모델
04_Market_Pulse_Index.ipynb	지수화 및 대시보드: 합성 지수(MarketEcho Index _t) 산출 및 캔들 차트 시각화, AI 해설 마커 구현.	최종 출력

1. 각 파일별 상세 역할 설명

00_Env.ipynb (Environment Setup)

- 프로젝트 전반에 쓰일 `base_path` 를 정의하고 필요한 모든 라이브러리를 한 번에 설치합니다.
- 코랩의 `Secrets` 를 통해 보안이 중요한 API 키들을 안전하게 호출하는 기초 세션을 만듭니다.

01_Data_Factory.ipynb (Data Ingestion)

- 야후 파이낸셜 뉴스와 주요 경제 지표(국채 금리, 금, 구리 등)를 실시간 및 누적 방식으로 수집합니다.
- 방금 수정하신 것처럼, Gemini가 이해하기 쉬운 `context_text` 컬럼을 생성하여 저장하는 핵심 공장입니다.

02_RAG_Architect.ipynb (Vector Database)

- 수집된 텍스트를 Gemini API를 통해 벡터로 변환하여 '**AI의 장기 기억 장치**'를 만듭니다.
- 사용자가 질문했을 때 수만 개의 뉴스 중 가장 관련 있는 정보를 1초 내에 찾아주는 검색 엔진을 구축합니다.

03_Sentiment_Analyzer.ipynb (Reasoning Engine)

- 검색된 뉴스 제목과 마켓 데이터를 Gemini API에게 전달하여, 경제 전문가 수준의 인과관계 분석을 수행합니다.
- $Sentiment_Score_i$
를 산출하여 다음 단계의 수식에 입력할 파라미터를 결정합니다.

04_Market_Pulse_Index.ipynb (Synthesis & Visualization)

- 기획안의 수식을 적용하여 가상의 지수를 계산하고, 이를 차트로 그려냅니다.

- $$MarketEcho\ Index_t = \sum_{i=1}^n (w_i \times Sentiment_Score_i)$$

수식을 코드로 구현하여 시각적인 결과물을 완성합니다.

MarketEcho Index: C4 Model 설계

Level 1: System Context (시스템 맥락 다이얼로그)

최상위 단계로, 사용자와 외부 시스템(Yahoo Finance, LLM) 간의 상호작용을 정의합니다.

- **Persona:** 초보 투자자, 대학생 (거시경제 흐름 파악 목적)
- **External Systems:** * **Yahoo Finance:** 실시간 뉴스 및 시황 데이터 공급원
 - **LLM API (OpenAI/Claude):** RAG 기반 근거 답변 생성 엔진
- **System:** MarketEcho Index (뉴스를 지수화하고 질문에 답변하는 핵심 서비스)

Level 1: 시스템 맥락 (System Context)

이 단계는 'MarketEcho Index'가 외부와 어떻게 상호작용하는지 정의하는 비즈니스 관점의 지도입니다.

1. 참여자 및 시스템 정의

- **사용자 (초보 투자자/대학생):** 거시경제 뉴스의 복잡한 인과관계를 이해하고 싶어 하는 유료 구독자입니다. 질문을 던지고 결과물(지수, 리포트)을 얻습니다.
- **소프트웨어 시스템 (MarketEcho Index):** 뉴스의 '메아리'를 분석하여 시장 영향력을 지수화하고, 데이터에 기반한 답변을 생성하는 핵심 서비스입니다.
- **외부 시스템 1 (Yahoo Finance):** 전 세계 실시간 뉴스 기사와 국채, 환율, 원자재 등의 시장 가격 데이터를 제공합니다.
- **외부 시스템 2 (LLM API - OpenAI/Claude):** 수집된 뉴스 문맥을 해석하여 인간이 읽기 편한 전문가 수준의 분석문을 생성합니다.

2. 시스템 간 상호작용

- **사용자 ↔ 시스템:** 사용자는 자연어로 질문("왜 환율이 올랐어?")을 보내고, 시스템은 마켓 지수 점수와 RAG 기반의 근거 답변, 그리고 시각화된 차트를 응답합니다.
- **시스템 → Yahoo Finance:** 시스템은 주기적으로 뉴스 기사와 시황 수치 데이터를 수집(Fetch)합니다.


- **시스템 ↔ LLM API:** 시스템은 검색된 뉴스 텍스트를 전달(Context)하고, LLM은 이를 요약 및 분석하여 다시 시스템으로 전송합니다.

다이얼로그 구성 요소 및 상호작용1. 웹 애플리케이션 (Web Application)

- 기술: Streamlit, Plotly
- 역할: 사용자 인터페이스(UI)를 담당합니다.
- 상세: 대화형 질문창을 제공하고, Plotly를 통해 시간 흐름에 따른 지수 차트와 핵심 영향 요인 트리맵을 시각화합니다. 사용자가 특정 시점을 클릭하면 해당 시점의 뉴스를 즉시 보여줍니다.

2. 분석 엔진 (Analysis Engine)

- 기술: Python (FastAPI/Flask)
- 역할: 서비스의 '지능'을 담당하는 심장부이며, ADP 방법론이 실제 구현되는 곳입니다.
- 상세 로직:
 - 텍스트 분석 고도화: NLTK와 KoNLPy를 활용해 뉴스 정제 및 감성 분석 (Bullish/Bearish 판별)을 수행합니다.
 - 통계적 검증: 산출된 지수와 실제 가격 데이터 간의 상관계수 ρ 를 계산하여 모델의 신뢰도를 점검하고 가중치를 조정합니다.
 - RAG 오케스트레이터: 사용자의 질문을 벡터로 변환하여 저장소에서 최적의 뉴스 문맥을 추출합니다.



Level 2: 컨테이너 설계 (Container Diagram)

이 단계는 시스템 내부를 쪼개어, 어떤 기술들이 어떤 역할을 하는지 구체적으로 정의하는 개발 관점의 설계도입니다.

1. 웹 애플리케이션 (Web Application)

- **기술:** Streamlit, Plotly
- **역할:** 사용자 인터페이스(UI)를 담당합니다.
- **상세:** 대화형 질문창을 제공하고, Plotly를 통해 시간 흐름에 따른 지수 차트와 핵심 영향 요인 트리맵을 시각화합니다. 사용자가 특정 시점을 클릭하면 해당 시점의 뉴스를 즉시 보여줍니다.

2. 분석 엔진 (Analysis Engine)

- **기술:** Python (FastAPI/Flask)
- **역할:** 서비스의 '지능'을 담당하는 심장부이며, **ADP 방법론**이 실제 구현되는 곳입니다.
- **상세 로직:**
 - **텍스트 분석 고도화:** NLTK와 KoNLPy를 활용해 뉴스 정제 및 감성 분석 (Bullish/Bearish 판별)을 수행합니다.
 - **통계적 검증:** 산출된 지수와 실제 가격 데이터 간의 상관관계수 p 를 계산하여 모델의 신뢰도를 점검하고 가중치를 조정합니다.
 - **RAG 오케스트레이터:** 사용자의 질문을 벡터로 변환하여 저장소에서 최적의 뉴스 문맥을 추출합니다.

3. 백그라운드 수집기 (Background Collector)

- **기술:** Python Schedule/Cron
- **역할:** 시스템의 자동화를 담당하는 엔진입니다.
- **상세:** 사용자의 요청 유무와 관계없이 정해진 시간마다 야후 파이낸스에서 뉴스를 크롤링하고, 전처리를 거쳐 데이터베이스에 미리 저장해둡니다. '실시간성'을 유지하는 핵심 컨테이너입니다.

4. 벡터 데이터베이스 (Vector DB)

- **기술:** ChromaDB 또는 FAISS
- **역할:** 비정형 데이터(뉴스 본문)의 저장소입니다.
- **상세:** 뉴스 기사를 임베딩(숫자화)하여 저장하며, RAG 답변 생성을 위해 질문과 가장 유사한 뉴스 문장을 빠르게 검색할 수 있게 합니다.

5. 메타데이터 저장소 (Metadata Store)

- **기술:** SQLite
- **역할:** 정형 데이터 및 사용자 관리용 저장소입니다.
- **상세:** 산출된 지수 점수(*MacroReactionIndex*), 뉴스 기사 메타정보(날짜, 출처), 그리고 **구독자의 결제 상태(\$5/mo)** 정보를 관리합니다.

6. 응답 캐시 (Response Cache)

- **기술:** In-memory Cache / Redis
- **역할:** 효율성과 비용 절감을 담당합니다.

- **상세:** 최근에 생성된 분석 답변을 임시 저장합니다. 동일하거나 유사한 질문이 들어오면 비싼 LLM API를 다시 호출하지 않고 캐시된 답변을 즉시 내보내 응답 속도를 높입니다.

Level 2: 컨테이너 간 상호작용 설계

1. 데이터 수집 및 가공 경로 (Background Flow)

사용자의 요청과 관계없이 시스템이 살아 움직이며 데이터를 준비하는 과정입니다.


- **수집기(Collector) → Yahoo Finance:** 주기적(예: 1시간 단위)으로 최신 뉴스 기사 본문과 주요 자산(금, 환율 등)의 시계열 가격 데이터를 가져옵니다.
- **수집기(Collector) → 분석 엔진(Engine):** 수집된 원문 데이터를 전달하여 ADP 기반의 전처리와 감성 분석 점수 산출을 요청합니다.
- **분석 엔진(Engine) → 벡터 데이터베이스(Vector DB):** 뉴스 본문을 임베딩(Embedding)하여 검색 가능한 형태로 저장합니다.
- **분석 엔진(Engine) → 메타데이터 저장소(Metadata Store):** 산출된 마켓 지수(*MacroReactionIndex*) 점수와 뉴스의 출처, 날짜 등 정형 데이터를 기록합니다.

2. 사용자 질의 및 분석 응답 경로 (User Request Flow)

사용자가 앱에 접속하여 질문을 던졌을 때 발생하는 실시간 흐름입니다.

- **사용자 → 웹 애플리케이션(UI):** 자연어 질문을 입력하거나 특정 기간의 지수 차트를 조회합니다.
- **웹 애플리케이션(UI) → 메타데이터 저장소(Metadata Store):** 현재 접속한 사용자의 ****구독 상태(\$5/mo)****를 확인하여 서비스 접근 권한을 인증합니다.
- **웹 애플리케이션(UI) → 분석 엔진(Engine):** 인증된 사용자의 질문(질의어)을 분석 엔진으로 전달합니다.
- **분석 엔진(Engine) → 응답 캐시(Cache):** 동일하거나 유사한 질문이 최근에 있었는지 확인하여, 있다면 LLM을 거치지 않고 즉시 답변을 반환합니다. (비용 및 속도 최적화)
- **분석 엔진(Engine) → 벡터 데이터베이스(Vector DB):** 캐시가 없을 경우, 질문과 가장 연관성이 높은 뉴스 문맥(Context) 상위 K개를 검색해 옵니다.
- **분석 엔진(Engine) → LLM API:** 검색된 뉴스 문맥과 질문을 결합하여 "근거 기반의 답변" 생성을 요청합니다.
- **분석 엔진(Engine) → 웹 애플리케이션(UI):** 최종 답변과 함께 시각화에 필요한 지수 데이터를 전달합니다.

- **웹 애플리케이션(UI) → 사용자:** Plotly 차트와 AI 리포트가 결합된 인사이트 화면을 최종 응답합니다.



Level 3: 컨테이너별 상세 컴포넌트 리스트 (The Hidden Components)

1. Web Application (Streamlit) 내의 컴포넌트

화면만 보여주는 게 아니라, 사용자의 요청을 처리하고 데이터를 정제하는 논리들이 들어갑니다.

- **Navigation Manager (라우터):** 대시보드(차트), RAG 채팅창, 구독 페이지 간의 화면 전환을 관리합니다.
- **State Manager (세션 관리):** 사용자가 이전 질문이 무엇이었는지, 현재 보고 있는 지수 기간이 언제인지 등의 '상태'를 유지합니다.

- **Visualization Wrapper (Plotly 엔진):** 분석 엔진에서 받은 원시 수치 데이터를 선 그래프, 트리맵 등 대화형 차트로 렌더링합니다.
- **Auth Proxy (인증 대행):** 사용자가 로그인을 했는지, \$5 결제권이 유효한지 확인하여 접근 권한을 제어합니다.

2. Analysis Engine (FastAPI) 내의 컴포넌트

가장 복잡한 곳입니다. 태영 님이 말씀하신 **ADP 방법론**이 모듈 단위로 쪼개져야 합니다.

- **NLP Pipeline (전처리기):** KoNLPy/NLTK를 사용하여 형태소 분석, 불용어 제거, 표제어 추출을 수행하는 텍스트 정제 전용 컴포넌트입니다.
- **Sentiment Scorer (감성 분석기):** 금융 사전을 기반으로 뉴스의 톤(Bullish/Bearish)을 수치화합니다.
- **Statistical Validator (ADP 검증기):** 산출된 지수와 실제 시장 가격 간의 상관계수 ρ 를 계산하고 회귀 분석을 통해 가중치를 동적으로 조정합니다.
- **Embedding Generator:** 텍스트를 벡터 DB가 이해할 수 있는 숫자(벡터)로 변환합니다.
- **Prompt Factory (프롬프트 관리자):** LLM에 보낼 질문의 서식(Template)을 관리하고, 검색된 뉴스 문맥을 최적으로 배치합니다.
- **LLM Connector:** OpenAI/Claude API와의 통신을 담당하며, 오류 시 재시도(Retry)나 할당량(Quota) 관리를 수행합니다.

3. Background Collector 내의 컴포넌트

- **Crawler Engine (수집기):** Yahoo Finance의 뉴스 및 시황 데이터를 긁어오는 핵심 로봇입니다.
- **Data Parser (파서):** 긁어온 HTML이나 JSON에서 기사 제목, 본문, 발행일자 등 필요한 정보만 뽑아냅니다.
- **Job Scheduler:** "매 1시간마다 실행"과 같은 타이밍을 관리하는 시계 역할을 합니다.
- **Update Trigger:** 데이터 수집이 끝나면 분석 엔진에 "새 데이터가 왔으니 지수를 다시 계산해!"라고 신호를 보냅니다.

4. Storage (DB) 관리 컴포넌트

단순히 저장만 하는 게 아니라, 데이터의 무결성을 지킵니다.

- **Subscription Manager:** SQLite 내의 결제 정보를 조회하고 만료 여부를 판별합니다.
- **Index Archivist:** 시간대별로 계산된 MarketEcho Index 점수를 시계열 형태로 누적 저장합니다.
- **Cache Controller:** Response Cache 내의 데이터가 너무 오래되면(Stale) 자동으로 삭제하고 새 답변으로 갱신합니다.